

Pour préserver la confidentialité des opinions individuelles, un sondage est effectué avec le protocole suivant. Chaque personne sondée doit, avant de répondre «oui» ou «non» à la question posée, réaliser confidentiellement (elle seule connaît le résultat) une variable de Bernoulli de paramètre  $a$ ,  $a \in ]0; 1[$  donné et connu du sondeur. Si le résultat est 1, la personne doit répondre à la question selon son avis. Si le résultat est 0, la personne doit répondre à la question selon le contraire de son avis. On suppose que les personnes sondées suivent parfaitement ce protocole et l'on note  $X_i$  la variable aléatoire qui vaut 1 si la  $i$ -ème personne sondée répond «oui» et 0 si elle répond «non». On note  $n$  le nombre de personnes sondées et  $p$  la proportion de personnes dont l'opinion personnelle est «oui» dans la population sondée. Soit  $q$  la probabilité qu'une personne sondée réponde «oui». Enfin, on suppose que  $a \neq \frac{1}{2}$ .

1. Exprimer  $q$  en fonction de  $p$  et  $a$ .

D'après l'énoncé de la situation et le théorème des probabilités totales,  $q = ap + (1-a)(1-p)$ .

2. Vérifier que  $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$  est un estimateur de  $q$  sans biais et convergent.

Chaque variable  $X_i$  suit une loi  $\mathcal{B}(q)$  donc  $\mathbb{E}(\bar{X}) = q$  :  $\bar{X}$  est un estimateur sans biais de  $q$ . Et  $V(\bar{X}) = \frac{q(1-q)}{n} \rightarrow 0$  donc  $\bar{X}$  est un estimateur convergent.

3. On pose

$$T_n = \frac{\bar{X} - 1 + a}{2a - 1}$$

Calculer l'espérance et la variance de  $T_n$ .

Par linéarité et d'après le calcul précédent, on trouve  $\mathbb{E}(T_n) = \frac{q-1+a}{2a-1} = p$ . D'après les règles de calcul pour la variance,

$$V(T_n) = \frac{1}{(a-1)^2} V(\bar{X} - 1 + a) = \frac{1}{(2a-1)^2} V(\bar{X}) = \frac{q(q-1)}{n(2a-1)^2}$$

Or en développant le calcul, on trouve  $q(q-1) = p(1-p)(2a-1)^2 + a(1-a)$  donc  $V(T_n) = \frac{p(1-p)}{n} + \frac{a(1-a)}{n(2a-1)^2}$

4. Démontrer que  $T_n$  est un estimateur de  $p$  sans biais et convergent.

Cela permet de voir que  $B(T_n) = p - p = 0$  et  $V(T_n) \rightarrow 0$  quand  $n \rightarrow +\infty$ .

5. Justifier que la variable  $\frac{T_n - p}{\sigma(T_n)}$  converge en loi vers la loi normale centrée réduite.

Pour pouvoir appliquer le théorème central limite, il suffit de vérifier que  $T_n$  s'écrit bien sous la forme d'une somme de variables aléatoires indépendantes et identiquement distribuées. En effet, on a

$$T_n = \frac{\frac{1}{n} \left( \sum_{i=1}^n X_i \right) - 1 + a}{2a - 1} = \frac{\frac{1}{n} \sum_{i=1}^n (X_i - 1 + a)}{2a - 1} = \sum_{i=1}^n \frac{X_i - 1 + a}{n(2a - 1)}$$

Les variables  $X_i$  étant i.i.d, les hypothèses sont bien vérifiées et d'après le théorème central limite, la variable  $\frac{T_n - \mathbb{E}(T_n)}{\sigma(T_n)}$  converge bien en loi vers une variable suivant une loi normale centrée réduite.

6. Donner une estimation de  $p$  par intervalle de confiance au niveau de confiance  $1 - \alpha$  que l'on notera  $I_\alpha$ .

D'après la question précédente, on peut (en supposant  $n$  grand) approcher la variable  $\frac{T_n - \mathbb{E}(T_n)}{\sigma(T_n)}$  par une variable  $Z$  qui suit une loi  $\mathcal{N}(0, 1)$ . Ensuite, on construit facilement un intervalle de confiance pour  $p = \mathbb{E}(T_n)$  au niveau  $1 - \alpha$  en choisissant dans la table la valeur  $u_{\alpha/2}$  permettant d'avoir

$$P(-u_{\alpha/2} < Z < u_{\alpha/2}) = 1 - \alpha$$

puis en redéployant l'inégalité autour de  $p$  :

$$P(T_n - u_{\alpha/2}\sigma(T_n) < \mathbb{E}(T_n) < T_n + u_{\alpha/2}\sigma(T_n)) = 1 - \alpha$$

D'où l'intervalle de confiance pour  $p = \mathbb{E}(T_n)$  :

$$I_{conf} = [T_n - u_{\alpha/2}\sigma(T_n); T_n + u_{\alpha/2}\sigma(T_n)]$$

Pour réaliser cet intervalle, il suffit de réaliser l'échantillon et de remplacer  $T_n$  et  $\sigma(T_n)$  par leurs réalisations. On obtiendra un intervalle par excès en remplaçant  $\sigma(T_n)$  par un majorant  $\frac{1/2}{\sqrt{n(2a-1)^2}}$

7. On fixe  $a = \frac{1}{6}$ ,  $n = 1000$  et on considère une réalisation de la variable aléatoire  $\bar{X}$  égale à 0,425. Déterminer une réalisation de l'intervalle de confiance utilisé pour l'estimation de  $p$  au risque  $\alpha = 0,05$  (on pourra utiliser la majoration  $q(1-q) \leq \frac{1}{4}$ ).

Application numérique : on trouve  $\alpha = 0.05$ , on utilise  $u_{\alpha/2} = 1.96$  et on trouve

$$I = [0.566; 0.658]$$